


金融LLMの「カンニング」を暴く：Look-Ahead-Bench

Point-in-Time（時点修正）モデルにおける時系列バイアスの標準化ベンチマーク



BASED ON "LOOK-AHEAD-BENCH" BY MOSTAPHA BENHENDA (2025)

バックテストの驚異的な数字は「蜃気楼」かもしれない

THE PROMISE

バックテストの驚異



FinGPTやBloombergGPTなどが金融工学を変革し、驚異的なパフォーマンスを報告している。

THE REALITY


致命的な欠陥



しかし、その成功の裏には致命的な欠陥が潜んでいる可能性がある。「ルックアヘッド・バイアス (先読みバイアス)」だ。モデルは市場を「予測」しているのではなく、学習データに含まれる未来の答えを「記憶」しているだけではないか？

なぜLLMは未来を知っているのか：学習データの汚染

LLM Pre-training Period
(LLM事前学習期間)



メカニズム

LLMはWeb規模のデータで事前学習される。そこには「2023年にNVIDIAがAIブームで急騰した」という事後的な解説記事が含まれている。

結果

2023年の株価予測を求めた際、モデルは推論を行っているのではなく、学習したニュース記事を「暗唱」しているに過ぎない。

致命的リスク

これにより、実運用（学習データ外）になった瞬間、パフォーマンスは崩壊する。

教室のテストではなく、市場のストレステストを

既存手法の限界



単なるQ&Aテストや事実の記憶テストでは、実際のトレーディング環境におけるバイアスを検出できない。

Look-Ahead-Benchのアプローチ



1. 実戦的ワークフロー：「AI Hedge Fund」フレームワーク（GitHub 4.5万スター）を用いた実際のポートフォリオ構築。
2. Alpha Decay（アルファ減衰）：学習期間内（In-Sample）と期間外（Out-of-Sample）のパフォーマンス差を定量化。

目的：記憶（Memorization）と推論（Reasoning）を峻別する

2つの期間を比較する「デュアル・ピリオド分析」



- 実験設計: 市場環境が類似した2つの期間 (Buy-and-Holdリターンが共に約+25%) を選定し、モデルの挙動を比較。
- 対象資産: 米国大型テック株 (Magnificent 7等: AAPL, NVDA, MSFT, TSLA, GOOGL)。

検証対象：汎用巨人 vs. 時系列特化モデル

Standard Models（汎用モデル）



- Llama 3.1 (8B/70B): カットオフ 2023年12月
- DeepSeek 3.2: カットオフ 2024年7月

リスク: P1の情報を「知ってしまった」可能性が高い。

PiT Models（時系列特化モデル）




- Pitinf Family (Small/Medium/Large)
- 設計: 2020年1月以降の情報を厳密に遮断

特徴: 真の「予測能力」のみで勝負する商用モデル。

嘘発見器としての指標：「アルファ減衰」

$$\alpha_{Decay} = \alpha_{P2} - \alpha_{P1}$$




定義: 期間P1 (過去) と期間P2 (未来) の超過リターン (アルファ) の差を測定。

判定基準:


- マイナス (大幅減): P1の成績は「カンニング (記憶)」によるものであったことを示唆。
- 安定/プラス: モデルが環境変化に適応し、普遍的な推論を行っていることを示唆。

結果1：標準モデルの崩壊



- DeepSeek 3.2: P1では圧倒的 (+20.73pp) な成績だが、P2で劇的に崩壊 (-21.77ppの減衰)。
- Llama 3.1: 8B, 70Bともに15pp以上の大幅な減衰を記録。
- 結論: 標準的なLLMは、未知の市場環境 (P2) に適応できず、過去の栄光 (P1) を再現できない。

パラドックス：賢いモデルほど「自信満々に間違ふ」




スケーリングの逆説 (Scaling Paradox):
標準モデルでは、サイズが大きくなるほどP2の成績が悪化する傾向が見られた。

The Memory Trap:
大規模モデルほど「記憶力」が良すぎるため、強い事前バイアス（思い込み）を持つ。

現象: 2024年の市場で、2021年の知識に基づいた「自信満々の幻覚（ハルシネーション）」を起こし、目の前のデータより記憶を優先してしまう。

結論: 優れた「記憶力」は、未知の環境下では致命的な「過学習」の罠となり、自信過剰な誤りを招く。

結果2：PiTモデルの「推論ボーナス」



安定性： Pitinfモデル群は、P1からP2にかけてパフォーマンスが維持・向上（Alpha Decayがプラス）。

Reasoning Dividend： 未来の情報のノイズ（カンニング）を取り除くことで、モデルサイズの拡大が「記憶」ではなく「純粋な金融推論能力」の向上に寄与する。

Pitinf-Large: +1.30ppのアルファ改善を記録。。真に未知の領域で戦えるのはPiTモデルのみ。

パフォーマンス比較データ一覧

モデル/戦略 (Model/Strategy)	P1 Alpha	P2 Alpha	Alpha Decay
DeepSeek 3.2	+20.73%	-1.04%	-21.77% (Worst)
Llama 3.1 8B	+13.81%	-3.42%	-17.23%
Quant (Momentum)	+7.96%	+5.75%	-2.21%
Quant (Mean Reversion)	-4.62%	-15.40%	-10.78%
Pitinf-Large	+6.02%	+7.32%	+1.30% (Best)

クオন্ツ運用への警鐘と教訓



バックテストは「蜃気楼」

標準LLMを用いたバックテスト結果は信頼に値しない。高い数値は過学習の証拠である可能性が高い。



写真記憶の弊害


正確すぎる記憶は、レジームチェンジ（市場環境の変化）への適応を阻害する。



導入の条件

実運用には、ルックアヘッド・バイアスを排除したPiTモデル、または厳密なデータカットオフ管理が不可欠である。

ベンチマークの拡張と今後の展望



結論：記憶を知性と混同してはならない

(Don't mistake memory for intelligence.)

Look-Ahead-Bench: 金融AIの「真の実力」を測るための必須診断ツール。

RESOURCES

Paper: [arXiv:2601.13770](https://arxiv.org/abs/2601.13770)

Code: github.com/benstaf/lookaheadbench

